

تحلیل RFM برای بخش بندی مشتریان با استفاده از

AdventureWorks

۱. چکیده اجرایی

این تحلیل روی داده فروش AdventureWorks انجام شده و 19,119 مشتری دارای سفارش، 31,465 سفارش و 109,846,381 دلار درآمد را در بازه 31 مه 2011 تا 30 ژوئن 2014 پوشش می دهد. تاریخ مرجع برای محاسبه Recency، اول ژوئیه 2014 در نظر گرفته شده است.

مهم ترین یافته این تحلیل در همان مراحل ابتدایی به دست آمد: مشتریان AdventureWorks یک جمعیت یکدست نیستند. بررسی توزیع نشان داد افراد و فروشگاه ها رفتار خرید کاملاً متفاوتی دارند. میانه فاصله بین دو سفارش متوالی برای فروشگاه ها 91 روز است و برای افراد 336 روز. یعنی یک فروشگاه در هر فصل سفارش می دهد و یک فرد تقریباً سالی یک بار.

این تفاوت پیامد روشی مستقیم داشت. اگر هر دو گروه با یک مقیاس امتیاز می گرفتند، در Frequency و Monetary تقریباً همه فروشگاه ها در بالاترین سطح و بیشتر افراد در سطوح پایین می نشستند و مدل قدرت تفکیک خود را از دست می داد. بنابراین امتیازدهی درون هر گروه به صورت جداگانه انجام شد.

برای تبدیل سه سنج به مقیاس یک تا پنج، سه تابع NTILE و CUME_DIST و PERCENT_RANK سنجیده شدند. NTILE که روش متعارف در تحلیل RFM است رد شد، چون 62.86 درصد مشتریان فردی دقیقاً یک سفارش دارند و NTILE ناچار می شود این توده هم رفتار را بین سه امتیاز مختلف پخش کند. انتخاب نهایی PERCENT_RANK بود.

توزیع درآمد به شدت نامتقارن است. فروشگاه های دارای نماینده فروش تنها 3.3 درصد مشتریان هستند ولی 73.3 درصد درآمد را تولید می کنند.

مشتریان بر اساس ترکیب سه امتیاز به هشت خوشه تقسیم شدند. بزرگ ترین خوشه از نظر درآمد، فروشگاه های فعال با تازگی میانی است که به تنهایی 26.2 درصد کل درآمد پروژه را در خود دارد.

از نظر ریسک، خوشه در خطر ریزش مهم ترین گروه است. این خوشه در مجموع دو گروه مشتری 23.4 درصد کل درآمد پروژه را نمایندگی می کند، یعنی حدود 25.7 میلیون دلار درآمد تاریخی متعلق به مشتریانی است که ارزش بالایی دارند ولی تازگی خریدشان افت کرده.

در سمت فرصت، 163 فروشگاه بیش از سه چرخه سفارش خود را از دست داده اند. درآمد تاریخی این گروه 12.99 میلیون دلار است. بررسی جداگانه نشان داد فروشگاه ها سفارش خود را به تاخیر نمی اندازند بلکه یک چرخه کامل را رد می کنند، و همین الگو تعریف دقیقی از غیبت به دست می دهد.

توصیه اصلی این است که تلاش بازگردانی از خوشه در خطر ریزش شروع شود، نه از فروشگاه هایی که بیشترین مدت غیبت را دارند. دلیلش این است که در میان فروشگاه های غایب، میانه غیبت خوشه در خطر ریزش 458 روز است در برابر 792 روز برای گروه ارزشمند غایب، و شانس بازگشت مشتری که تازه تر غایب شده بیشتر است. این نکته آخر یک فرض است و در بخش محدودیت ها به آن اشاره شده.

مهم ترین محدودیت این تحلیل، ضعف بعد Frequency است. چون 92.4 درصد مشتریان فردی فقط یک یا دو سفارش دارند، این بعد در عمل نمی تواند پنج سطح تفکیک تولید کند و مدل عملاً دوبعدی عمل می کند. همچنین RFM رفتار گذشته را می سنجد و پیش بینی آینده نیست، حاشیه سود را در نظر نمی گیرد، و به بازه زمانی داده حساس است.

۲. مدل RFM

۲.۱ مدل RFM چیست؟

مدل RFM یک روش بخش بندی مشتریان است که رفتار خرید هر مشتری را با سه سنجه توصیف می کند.

سنجه	تعریف
Recency	فاصله آخرین خرید مشتری از تاریخ مرجع
Frequency	تعداد دفعات خرید مشتری
Monetary	جمع مبلغ خرید مشتری

۲.۲ چرا هر سنجه مهم است؟

Recency: مهم است چون فرق بین مشتری فعال و مشتری در حال فاصله گرفتن را مشخص می کند و برای بازاریابی درست، برای این دو باید برنامه های متفاوتی در نظر گرفته شود.

Frequency: نشان می دهد رابطه مشتری با شرکت چقدر پایدار است. با آن می توان مشتری ثابت را از مشتری تک سفارشی جدا کرد و برای هر دسته برنامه متفاوتی در نظر گرفت.

Monetary: ارزش هر مشتری را مشخص می کند و برنامه بازاریابی باید متناسب با همین ارزش طراحی شود.

۲.۳ چرا هر سه باید باشند؟

اگر یکی از این سه سنجه نباشد، نمی توان تحلیل رفتاری درستی از مشتری داشت. به طور مثال اگر Recency و Frequency مشخص باشند و Monetary مشخص نباشد، ممکن است مشتری که تعداد بالایی خرید کرده و آخرین خریدش هم تازه بوده ولی مبالغ خریدهایش ناچیز است، به جای دسته کم ارزش در دسته پرارزش قرار بگیرد.

این حالت در همین پروژه دیده شد. خوشه خرده خرید وفادار در گروه مشتریان فردی 745 نفر دارد که میانه تعداد سفارششان 2 است. این عدد در گروه مشتریان فردی جزو بالاترین ها محسوب می شود، چون 62.86 درصد این گروه فقط یک سفارش دارند. ولی میانه مبلغ خرید همین مشتریان فقط 68.70 دلار است. اگر Monetary در مدل نبود، این مشتریان کنار مشتریان واقعا پرارزش قرار می گرفتند، در حالی که سهم کل این خوشه از درآمد پروژه 0.04 درصد است.

دو سنجه دیگر هم به همین اندازه مهم هستند و حذف هر کدام خطای مشابهی ایجاد می کند.

۲.۴ کاربرد بازاریابی

تخصیص بودجه بر اساس ارزش: منابع بازاریابی محدود است و RFM نشان می دهد این منابع باید کجا صرف شوند. در داده این پروژه، فروشگاه های دارای نماینده فروش فقط 3.3 درصد مشتریان هستند ولی 73.3 درصد درآمد را تولید می کنند. تلاش یکسان روی همه مشتریان، بیشتر بودجه را صرف گروهی می کند که کمترین سهم را در درآمد دارد.

۲.۵ مزایا

معیارها ساده و قابل فهم هستند و اندازه گیری آن ها هم کار نسبتا ساده ای است. رفتار واقعی مشتری سنجیده می شود، نه چیزی که مشتری درباره خودش اظهار می کند. نیازی به داده بیرونی نیست و همه چیز از سوابق فروش خود شرکت به دست می آید. می توان آن را با SQL اجرا کرد و به ابزار یا مدل پیچیده ای نیاز نیست.

۲.۶ محدودیت ها

رفتار گذشته را می سنجد و پیش بینی آینده نیست. مشتری که تا دیروز پر خرید بوده، لزوما فردا هم پر خرید نیست. حاشیه سود را در نظر نمی گیرد. مشتری که مبلغ زیادی خرید کرده ولی همه خریدش از محصولات کم سود بوده، در این مدل پرازش به نظر می رسد. به بازه زمانی داده حساس است. داده این پروژه حدود سه سال است و اگر پنج سال بود، آستانه های امتیازدهی و تعریف مشتری غایب تغییر می کرد. مشتری تک سفارشی تازه وارد را از مشتری تک سفارشی راکد تفکیک نمی کند، چون هر دو Frequency برابر یک دارند. در این پروژه با نگه داشتن تاریخ اولین سفارش تا حدی جبران شد. فرض می کند یک آستانه واحد برای همه مشتریان معنا دارد. بررسی چرخه سفارش در این پروژه نشان داد میانه فاصله بین دو سفارش برای فروشگاه ها 91 روز و برای افراد 336 روز است. یعنی یک فروشگاه که 200 روز سفارش نداده نگران کننده است ولی یک فرد با همان فاصله کاملاً عادی رفتار می کند. این فرض در حضور گروه های رفتاری متفاوت نادرست است.

بعد Frequency در این داده قدرت تفکیک پنج سطحی ندارد. 92.4 درصد مشتریان فردی فقط یک یا دو سفارش دارند، پس امتیاز Frequency عملاً به دو سطح محدود می شود و مدل در این گروه دوبعدی عمل می کند.

۳. داده و روش

۳.۱ منابع داده و دامنه

این تحلیل روی نسخه OLTP پایگاه داده ۲۰۲۲ AdventureWorks و در محیط ۲۰۲۲ SQL Server انجام شده است. دو جدول اصلی که در صورت پروژه تعیین شده بودند، Sales.SalesOrderHeader و Sales.SalesOrderDetail هستند که از طریق ستون SalesOrderID به هم متصل می شوند. برای تعیین نوع مشتری، جدول Sales.Customer هم به این دو اضافه شد.

مقدار	مورد
31,465	سفارش ها (SalesOrderHeader)
121,317	اقلام سفارش (SalesOrderDetail)
حدود 3.9	میانگین قلم در هر سفارش
19,820	کل مشتریان
19,119	مشتریان دارای سفارش
701	مشتریان بدون سفارش

بازه زمانی داده از 31 مه 2011 تا 30 ژوئن 2014 است. سال های 2011 و 2014 کامل نیستند، پس هر مقایسه سالانه فقط بین 2012 و 2013 منصفانه است. همه سفارش ها وضعیت ارسال شده دارند و به فیلتر روی ستون Status نیازی نبود.

در مرحله شناخت داده مشخص شد مشتریان سه نوع هستند. مبنای این تفکیک ستون های StoreID و PersonID در جدول Sales.Customer است. مشتری بدون StoreID یک فرد است، مشتری با StoreID ولی بدون PersonID فروشگاهای بدون نماینده فروش، و مشتری با هر دو ستون فروشگاهای دارای نماینده فروش. ستون OnlineOrderFlag در ابتدا برای این کار بررسی شد ولی کنار گذاشته شد، چون کانال ثبت سفارش را نشان می دهد نه نوع مشتری را.

نوع مشتری	تعداد	سفارش	درآمد (میلیون دلار)
Individual	18,484	27,659	29.36
Store with rep	635	3,806	80.49
Store without rep	701	0	0

هر 701 مشتری بدون سفارش دقیقا همان فروشگاه های بدون نماینده فروش هستند. این گروه چون سفارشی ندارد، هیچ کدام از سه سنجه RFM برایش قابل محاسبه نیست و از تحلیل خارج شد.

۳.۲ تعاریف عملیاتی

تاریخ مرجع برای محاسبه Recency، روز بعد از آخرین سفارش موجود در داده یعنی اول ژوئیه 2014 انتخاب شد. چون داده ایستاست و تاریخ امروز معنایی برای آن ندارد، آخرین تاریخ موجود مبنای منطقی تری است. اضافه کردن یک روز باعث می شود هیچ مشتری Recency برابر صفر نگیرد. این تاریخ در کد با قالب YYYY-MM-DD نوشته شده، چون نسخه اول با قالب روز ماه سال نوشته شده بود و SQL Server آن را هفتم ژانویه خواند.

سنجه	تعریف	محاسبه	دامنه در داده
Recency	تعداد روز از آخرین سفارش تا تاریخ مرجع	DATEDIFF روی LastOrderDate و 2014-01-07	1 تا 1,127 روز
Frequency	تعداد سفارش های مشتری	شمارش SalesOrderID	1 تا 28 سفارش
Monetary	جمع مبلغ خرید مشتری	SUM روی LineTotal	1.37 تا 877,107 دلار

برای Monetary دو گزینه وجود داشت: ستون LineTotal در جدول ارقام و ستون TotalDue در جدول سفارش. TotalDue شامل مالیات و هزینه حمل است که درآمد شرکت محسوب نمی شوند و حدود 12 درصد با جمع LineTotal فاصله دارد. پس LineTotal انتخاب شد که با تعریف صورت پروژه هم یکی است. این ستون یک ستون محاسباتی است و تخفیف از قبل در آن اعمال شده. جمع کل آن 109,846,381.40 دلار است. باید توجه داشت این عدد درآمد ناخالص است و حاشیه سود را نشان نمی دهد.

۳.۳ معماری کد

مهم ترین خطر در ساخت مجموعه پایه، تکثیر ردیف ها هنگام جوین است. هر سفارش به طور میانگین 3.9 قلم دارد، پس اگر جدول ارقام مستقیم به جدول سفارش جوین شود و بعد روی ستون های سطح سفارش شمارش انجام شود، تعداد سفارش هر مشتری تقریبا چهار برابر شمرده می شود. این خطا تصادفی هم نیست و مشتریانی که سبد بزرگ تری دارند به صورت سیستماتیک متورم می شوند.

برای جلوگیری از این مشکل، مجموعه پایه در چهار لایه ساخته شد:

کار	سطح داده	لایه
جمع LineTotal هر سفارش از جدول اقلام	سفارش	OrderLevelRevenue
جوین با جدول سفارش و افزودن تاریخ و شناسه مشتری	سفارش	OrderWithCustomer
تجمیع تا سطح مشتری	مشتری	CustomerDetail
جوین با Sales.Customer و ساخت ستون نوع مشتری	مشتری	CustomerData

چون جدول اقلام قبل از جوین تا سطح سفارش تجمیع شده، رابطه با جدول سفارش یک به یک می شود و خطر تکثیر کاملاً از بین می رود. جوین با Sales.Customer هم عمداً بعد از تجمیع انجام شده تا روی 19,119 ردیف اجرا شود نه 31,465 ردیف.

خروجی این چهار لایه به شکل یک View با نام rfm.vw_CustomerRFM در یک Schema اختصاصی ذخیره شد. اسکریپت ساخت آن با بررسی وجود Schema و حذف View قبلی نوشته شده، پس اجرای مکرر آن خطا نمی دهد.

مراحل بعدی روی همین View و با زنجیره ای از CTE ها ساخته شدند. حداقل سه لایه در این زنجیره اجباری است، چون یک Window Function نمی تواند در همان سطحی که تجمیع انجام می شود روی نتیجه تجمیع اعمال شود، و نام مستعار یک Window Function در همان SELECT قابل استفاده دوباره نیست.

کار	لایه
محاسبه PERCENT_RANK برای هر سه سنج	Percentiles
تبدیل درصدها به امتیاز یک تا پنج	Scores
تخصیص هر مشتری به یک خوشه	Segments

امتیازها و خوشه ها به عنوان شی جدید در پایگاه داده ذخیره نشدند و این زنجیره در فایل های بعدی تکرار شده است. این انتخاب ریسک واگرایی بین فایل ها دارد. برای کنترل این ریسک، در مرحله تحلیل کسب و کار تعداد اعضای خوشه ها با جدول پروفایل مقایسه شد و تطابق کامل داشت.

کد پروژه در ده فایل با شماره ترتیبی از 00 تا 09 سازمان دهی شده که ترتیب اجرا را نشان می دهد. فهرست فایل ها در پیوست آمده است.

۴. تحلیل توزیع

قبل از انتخاب روش امتیازدهی باید شکل توزیع هر سه سنجه مشخص می شد، چون انتخاب Window Function مستقیماً به آن بستگی دارد. همه بررسی های این بخش به تفکیک نوع مشتری انجام شد.

۴.۱ آمار توصیفی به تفکیک نوع مشتری

سنجه	Individual	Store with rep
تعداد مشتری	18,484	635
بیشترین Recency	1,127	1,035
کمترین Recency	1	61
تعداد سفارش	27,659	3,806
میانگین Frequency	1.50	5.99
بیشترین Frequency	28	12
کمترین Frequency	1	1
درآمد کل	29,358,677.22	80,487,704.18
میانگین Monetary	1,588.33	126,752.29
بیشترین Monetary	13,295.38	877,107.19
کمترین Monetary	2.29	1.37

مقیاس دو گروه کاملاً متفاوت است، ولی نکته مهم تر این است که شکل توزیعشان هم فرق دارد. گروه Individual میانگین Frequency برابر 1.50 و سقف 28 دارد و گروه Store میانگین 5.99 و سقف 12. یعنی دم بلند توزیع Frequency به افراد تعلق دارد نه فروشگاه ها، برخلاف انتظار اولیه.

علاوه بر این کمترین Recency گروه Store برابر 61 است در برابر 1 برای Individual. یعنی هیچ فروشگاهی در 61 روز پایانی داده سفارش ثبت نکرده. اگر Recency دو گروه با هم امتیاز می گرفت، هر 635 فروشگاه به دلیلی ساختاری در پایین ترین سطح تازگی قرار می گرفتند.

۴.۲ توزیع Frequency

هدف این بررسی این بود که مشخص شود آیا توزیع Frequency اجازه استفاده از NTILE را می دهد یا نه. NTILE جمعیت را به پنج بخش مساوی تقسیم می کند و به مقدار داده کاری ندارد. اگر یک مقدار واحد بیش از یک پنجم جمعیت را در بر بگیرد، مشتریانی با رفتار کاملاً یکسان امتیازهای متفاوت می گیرند و این تفاوت از ترتیب دلبخواه موتور پایگاه داده می آید نه از داده.

گروه Individual

سهم تجمعی (درصد)	سهم از گروه (درصد)	تعداد مشتری	Frequency
62.86	62.86	11,619	1
92.37	29.51	5,454	2
98.68	6.31	1,166	3
99.49	0.81	150	4
100.00	0.51	95	5 تا 28

گروه Store with rep

سهم تجمعی (درصد)	سهم از گروه (درصد)	تعداد مشتری	Frequency
4.72	4.72	30	1
7.72	2.99	19	2
13.70	5.98	38	3
50.87	37.17	236	4
53.86	2.99	19	5
56.85	2.99	19	6
62.05	5.20	33	7
85.51	23.46	149	8
87.09	1.57	10	9
88.35	1.26	8	10
89.92	1.57	10	11
100.00	10.08	64	12

در گروه Individual یک مقدار واحد 62.86 درصد جمعیت را دارد و در گروه Store دو مقدار 4 و 8 به ترتیب 37.17 و 23.46 درصد. هر سه از 20 درصد، یعنی اندازه یک کوینتایل، بزرگ ترند. پس NTILE برای Frequency در هر دو گروه کنار گذاشته شد. جزئیات این تصمیم در بخش ۵ آمده است.

نکته دیگر الگوی مضرب چهار در گروه Store است. مقادیر 4 و 8 و 12 روی هم 70.7 درصد فروشگاه ها را شامل می شوند، که اولین نشانه از یک الگوی خرید دوره ای بود.

۴.۳ تمرکز مقدار در Recency و Monetary

همین آزمون برای دو سنج دیگر هم انجام شد و برای هر سنج در هر گروه، سهم پرتکرارترین مقدار از جمعیت گروه اندازه گیری شد. پرتکرارترین مقدار Recency در گروه Store همان 61 روز است که 28.19 درصد فروشگاه ها را در بر می گیرد. پرتکرارترین مقدار Monetary در گروه Individual مبلغ 4.99 دلار است، که

مربوط به مشتریان تک سفارشی و تک قلمی زیر 5 دلار است. در سه ترکیب دیگر سهم پرتکرارترین مقدار از 3 درصد کمتر است. نتیجه کامل این آزمون در جدول شش خانه ای بخش ۵ آمده است.

۴.۴ صدک های Monetary

هدف این بررسی مشخص کردن شدت چولگی توزیع Monetary بود. تحلیل میانگین بدون میانه در یک توزیع چوله تا حد زیادی بی معنی است.

Store with rep	Individual	صدک
1,822.10	24.27	P۱۰
7,497.04	49.97	P۲۵
45,502.97	270.26	P۵۰ (میانه)
176,784.40	2,511.28	P۷۵
386,028.62	4,826.84	P۹۰
744,504.75	8,129.02	P۹۹
126,752.29	1,588.33	میانگین

تفسیر	Store with rep	Individual	نسبت
در توزیع متقارن حدود 1	2.79	5.88	میانگین به میانه
بالاترین مشتریان چند برابر مشتری معمولی	16.4	30.1	P۹۹ به میانه
پراکندگی نیمه میانی جمعیت	23.6	50.3	P۷۵ به P۲۵

میانگین Monetary در گروه ۵.۸۸ Individual برابر میانه است. یعنی میانگین این گروه نماینده هیچ مشتری واقعی نیست و در ادامه پروژه برای توصیف خوشه ها از میانه استفاده شد نه میانگین.

در گروه Individual بیشترین پراکندگی در بخش میانی توزیع است نه در انتهای آن. از P۲۵ تا P۵۰ مبلغ حدود پنج برابر می شود و از P۵۰ تا P۷۵ حدود نه برابر، در حالی که از P۷۵ تا P۹۹ فقط حدود سه برابر. گروه Store چولگی کمتری دارد.

۴.۵ توزیع Recency و آزمون چرخه سفارش

نتایج بررسی های قبلی این احتمال را مطرح کرد که فروشگاه ها به صورت دوره ای خرید می کنند. اگر این درست باشد، Recency برای دو گروه معنای یکسانی ندارد: 100 روز غیبت برای فروشگاه های که هر فصل خرید می کند نگران کننده است ولی برای فردی که سالی یک بار خرید می کند عادی است.

نوع مشتری	مشتریان چندسفرشی	میانگین فاصله (روز)	میان فاصله (روز)
Individual	6,865	372.53	336
Store with rep	605	102.21	91

میان 91 روز برای فروشگاه ها تقریباً دقیقاً برابر یک فصل تقویمی است. این فرضیه بعداً در بخش ۸ با بررسی مستقیم فاصله سفارش های متوالی هر فروشگاه دوباره آزمون و تایید شد.

بازه Recency (روز)	Individual تعداد	Individual درصد	Store تعداد	Store درصد
0 تا 90	4,815	26.05	179	28.19
90 تا 180	4,973	26.90	277	43.62
180 تا 365	7,774	42.06	26	4.09
365 تا 730	640	3.46	96	15.12
بیشتر از 730	282	1.53	57	8.98

توزیع Recency دو گروه تقریباً معکوس است. 71.8 درصد فروشگاه ها Recency کمتر از 180 روز دارند در برابر 52.9 درصد افراد، ولی 24.1 درصد فروشگاه ها بیش از یک سال غایب اند در برابر 4.99 درصد افراد. بازه صفر تا 90 روز در گروه Store دقیقاً 179 مشتری دارد که همه Recency برابر 61 دارند. یعنی همه فروشگاه های فعال در 90 روز اخیر در یک روز واحد سفارش داده اند. این فروشگاه ها را کد نیستند و این هم زمانی با چرخه دوره ای سازگار است.

۴.۶ جمع بندی: چرا امتیازدهی جداگانه

شواهد این بخش به یک تصمیم مشترک رسیدند:

#	شاهد
1	میانگین Frequency فروشگاه ها 5.99 در برابر 1.50 برای افراد
2	میانگین Monetary فروشگاه ها حدود 80 برابر افراد
3	شکل توزیع Frequency معکوس است: سقف 28 برای افراد در برابر 12 برای فروشگاه ها
4	کمترین Recency فروشگاه ها 61 روز در برابر 1 روز برای افراد
5	میان فاصله سفارش 91 روز برای فروشگاه ها در برابر 336 روز برای افراد (قوی ترین شاهد)
6	میانگین مبلغ خرید خوشه ارزش پایین در گروه Store برابر 1,362 دلار است، یعنی پنج برابر میانگین کل گروه Individual (بخش ۷)

تصمیم: هر دو گروه در تحلیل باقی ماندند، ولی امتیازدهی هر سه سنج درون هر گروه جداگانه انجام شد.

۵. انتخاب Window Function

۵.۱ مسئله

مدل RFM سه سنجه با واحدهای ناهمگن تولید می کند: Recency بر حسب روز، Frequency بر حسب تعداد سفارش و Monetary بر حسب دلار. جمع یا مقایسه مستقیم این سه معنا ندارد. برای رسیدن به یک مقیاس مشترک، هر سنجه باید به امتیازی رتبه ای بین 1 تا 5 تبدیل شود. صورت پروژه سه تابع NTILE و CUME_DIST و PERCENT_RANK را برای این کار معرفی کرده بود و هر سه سنجیده شدند.

۵.۲ بررسی NTILE

NTILE(۵) جمعیت را به پنج بخش با اندازه تقریباً مساوی تقسیم می کند. این کار زمانی درست است که داده به اندازه کافی پیوسته باشد. اگر توده ای از مشتریان مقدار کاملاً یکسان داشته باشند و آن توده بزرگ تر از یک پنجم جمعیت باشد، مرز کوینتایل به ناچار از وسط توده عبور می کند و مشتریان هم رفتار امتیازهای متفاوت می گیرند، فقط بر اساس ترتیب دلبخواه موتور.

معیار رد، تعریف شده پیش از دیدن داده: اگر سهم پرتکرارترین مقدار واحد یک سنجه از 20 درصد جمعیت گروهش بیشتر باشد، NTILE(۵) برای آن سنجه در آن گروه رد می شود. عدد 20 انتخاب شد چون اندازه دقیق یک کوینتایل است.

معیار	Individual	Store with rep
Recency	Pass (۰.۵۱)	Fail (۲۸.۱۹)
Frequency	Fail (۶۲.۸۶)	Fail (۳۷.۱۷)
Monetary	Pass (۲.۶۷)	Pass (۰.۴۷)

اعداد داخل پرانتز سهم پرتکرارترین مقدار از جمعیت گروه به درصد است. سه خانه از شش رد شدند. مشکل به یک سنجه محدود نیست و به ترکیب سنجه و گروه بستگی دارد.

برای اینکه اثر این مشکل مستقیم دیده شود، NTILE(۵) روی Frequency اجرا شد و بالاترین مقدار Frequency در هر کوینتایل استخراج شد:

کوینتایل	بالاترین Frequency در Individual	بالاترین Frequency در Store with rep
1	1	4
2	1	4
3	1	7
4	2	8
5	28	12

مقدار Frequency برابر 1 در گروه Individual سقف سه کوینتایل نخست است و مقدار 4 در گروه Store سقف دو کوینتایل نخست. یعنی NTILE مشتریانی را که مقدار کاملاً یکسان دارند بین چند امتیاز پخش کرده، فقط بر اساس ترتیب دلبخواه موتور و نه هیچ تفاوت رفتاری. نتیجه: NTILE رد شد.

۵.۳ بررسی CUME_DIST

تابع	سوال
PERCENT_RANK	چه کسری اکیدا پایین تر از من است
CUME_DIST	چه کسری پایین تر یا برابر من است

تفاوت در گنجانیدن خود ردیف و هم رتبه هایش در شمارش است. روی داده پیوسته این تفاوت ناچیز است، ولی روی توده های بزرگ هم مقدار تعیین کننده می شود. مثال عینی، مشتریان تک سفارشی گروه Individual هستند که 62.86 درصد جمعیت گروه اند:

تابع	مقدار	امتیاز با مرزهای 0.2 تا 0.8
PERCENT_RANK	0.0000	1
CUME_DIST	0.6286	4

CUME_DIST به کم فعال ترین مشتریان مجموعه امتیاز 4 از 5 می دهد، فقط به این دلیل که تعدادشان زیاد است. امتیاز باید بگوید مشتری چه کسانی را پشت سر گذاشته، نه اینکه خودش چقدر پرجمعیت است. نتیجه: CUME_DIST رد شد.

۵.۴ بررسی PERCENT_RANK

PERCENT_RANK سه ویژگی دارد که آن را برای این داده مناسب می کند.

اول، توده های هم مقدار را نمی شکند. همه مشتریانی که مقدار یکسانی در یک سنجه دارند، امتیاز یکسان می گیرند. این دقیقاً همان چیزی است که NTILE نقض می کرد.

دوم، هم رتبه های خودش را در شمارش وارد نمی کند. پاسخ می دهد چه کسری اکیدا پایین تر از من است، نه چه کسری پایین تر یا برابر من است. این تفاوت باعث می شود جمعیت یک توده به خودش امتیاز ندهد، که ایراد CUME_DIST بود.

سوم، یک تابع و یک منطق برای هر سه سنجه. مرزهای یکسان 0.2 تا 0.8 روی هر سه سنجه و هر دو گروه اعمال می شود و امتیازها بین سنجه ها و بین گروه ها قابل مقایسه می مانند.

تصمیم: PERCENT_RANK انتخاب شد.

۵.۵ هزینه این انتخاب

انتخاب PERCENT_RANK انتخاب کم ضررترین گزینه است، نه گزینه بی عیب. تازه ترین مشتریان گروه Store یک توده 179 نفری با Recency برابر 61 هستند. چون 456 فروشگاه از 634 فاصله ممکن پایین ترشان است، بالاترین PERCENT_RANK این گروه 0.7192 می شود و از مرز 0.8 عبور نمی کند. در نتیجه امتیاز 5 در Recency گروه Store به هیچ مشتری تعلق نمی گیرد.

این دقیقاً قرینه ایرادی است که باعث رد CUME_DIST شد:

تابع	رفتار با توده بزرگ هم مقدار
CUME_DIST	امتیاز ناحق بالا می دهد، چون خود توده را در شمارش می آورد
PERCENT_RANK	امتیاز ناحق پایین می دهد، چون توده نمی تواند از خودش جلو بزند
NTILE	امتیاز دلبخواه می دهد، چون توده را می شکند

هیچ یک از سه تابع روی این داده بی عیب نیست. تفاوت در این است که خطای PERCENT_RANK قابل مشاهده و قابل توضیح است: سطح خالی در خروجی دیده می شود و دلیلش با یک کوئری قابل اثبات است. خطای NTILE بی صداست و در خروجی به شکل توزیع سالم ظاهر می شود.

۵.۶ توزیع امتیازها

بعد از امتیازدهی، تعداد مشتریان در هر سطح امتیاز شمرده شد. این سطوح به هیچ مشتری نرسیدند:

گروه	سنجه	سطوح غایب
Individual	Frequency	2 و 3
Store with rep	Frequency	2
Store with rep	Recency	5

فشرده‌گی سطوح Frequency در گروه Individual یک یافته است نه نقص روش. داده واقعا پنج سطح تفکیک ندارد، چون 92.4 درصد این گروه فقط یک یا دو سفارش دارند. PERCENT_RANK این کمبود را صادقانه نشان می‌دهد و NTILE آن را پنهان می‌کند.

در مقابل، Monetary گروه Store کاملا یکنواخت تقسیم شد: هر پنج سطح دقیقا 127 مشتری دارند. یعنی وقتی داده تنوع کافی دارد، PERCENT_RANK همان تقسیم مساوی NTILE را بدون شکستن توده تولید می‌کند.

بررسی	نتیجه	حکم
حفظ تعداد ردیف‌ها	19,119	Pass
امتیاز خارج از بازه یا خالی	صفر در هر شش شمارنده	Pass
حضور هر دو سر طیف امتیاز	چهار خانه خالی از سی خانه	Fail، توضیح داده شده
درستی جهت امتیاز Recency	تازه ترها امتیاز بالاتر گرفتند	Pass
حفظ تعداد سفارش و مبلغ کل	31,465 و 109,846,381.40	Pass

۵.۷ پیاده سازی

سه فراخوانی PERCENT_RANK در یک CTE، هر کدام با ORDER BY PARTITION BY CustomerType و ORDER BY روی سنجه خودش. سپس یک لایه CASE درصدها را به امتیاز 1 تا 5 تبدیل می کند.

موضوع	تصمیم
تفکیک گروه	PARTITION BY CustomerType در هر سه فراخوانی. بدون آن، رتبه هر فروشگاه در برابر 18,484 فرد محاسبه می شد
جهت Recency	نزولی روی خود Recency، چون در این سنجه عدد کمتر بهتر است
جهت Frequency و Monetary	صعودی، چون عدد بیشتر بهتر است
مرزها	0.2 و 0.4 و 0.6 و 0.8، یکسان برای هر دو گروه. تفاوت رفتاری گروه ها از طریق پارتیشن اعمال می شود نه از طریق مرز
لایه بندی	نام مستعار یک Window Function در همان SELECT قابل استفاده دوباره نیست، پس CASE در لایه بعدی قرار می گیرد

۵.۸ پیامد برای تفسیر

نبود امتیاز 5 در Recency گروه Store نباید به معنای نبود مشتری تازه در این گروه تعبیر شود. بالاترین امتیاز موجود هر گروه، و نه عدد ثابت 5، مبنای تفسیر است. در گروه Store، امتیاز 4 همان تازه ترین مشتریان است.

۶. خوشه بندی

۶.۱ روش

خوشه بندی با CASE روی سه تایی امتیازها انجام شد نه با جمع امتیازها. جمع امتیازها تضاد بین ابعاد را از بین می برد: ترکیب 5 و 1 و 1 با ترکیب 1 و 3 و 3 هر دو جمع 7 می دهند، در حالی که اولی مشتری تازه ای است که فقط یک بار خرید کرده و دومی مشتری است که مدتی خرید منظم داشته و حالا فاصله گرفته. برچسب در معرض خطر که در صورت پروژه مثال زده شده، ذاتا بر همین تضاد بنا شده است.

برچسب ها و مرزها برای هر دو گروه مشترک هستند، چون امتیازها قبلا درون هر گروه نسبی شده اند.

۶.۲ قواعد خوشه بندی

اولویت	برچسب	معادل فارسی	RScore	FScore	MScore
1	High Value	ارزش بالا	4 یا 5	4 یا 5	4 یا 5
2	Churn Risk	در خطر ریزش	1 یا 2	4 یا 5	4 یا 5
3	High Value Lapsed	ارزشمند غایب	1 یا 2	1	4 یا 5
4	New Customer	مشتری جدید	4 یا 5	1	بی اهمیت
5	Loyal Small Spender	خرده خرید وفادار	بی اهمیت	4 یا 5	1 یا 2
6	Medium Value	ارزش متوسط	3 تا 5	بی اهمیت	3
7	Low Value	ارزش پایین	1 یا 2	1	1
8	Mid Recency Active	فعال با تازگی میانی	باقی مانده	باقی مانده	باقی مانده

ترتیب سطرها عمدی است و از خاص به عام می رود. CASE از بالا به پایین پیش می رود و در اولین شرط درست متوقف می شود، پس جابه جایی سطرها نتیجه را تغییر می دهد.

۶.۳ اصلاحات در طول کار

تعارض دو قاعده: قاعده New Customer و Medium Value همپوشانی دارند و در مجموع 944 مشتری شرط هر دو را دارند. به خاطر ترتیب CASE این مشتریان در New Customer قرار می گیرند. رفع کامل این تعارض نیازمند قید Frequency روی Medium Value بود، ولی امتیاز Frequency در گروه Individual هرگز مقدار 3 نمی گیرد. پس تعارض با ترتیب CASE مدیریت شد.

تفکیک سطل باقی مانده: در نسخه اول، مشتریانی که به هیچ قاعده ای نمی خوردند برچسب Low Value می گرفتند. چون Low Value یک قضاوت درباره ارزش است، این سطل به دو برچسب تقسیم شد: Low Value با

شرط صریح، و یک برچسب جدا برای مشتریانی که در هیچ الگوی دیگری نمی گنجند. این تفکیک هیچ مشتری را بین خوشه ها جابه جا نمی کند.

تغییر نام دو برچسب: High Value One-Time به High Value Lapsed تغییر کرد، چون پروفایل نشان داد میانه Frequency این خوشه در گروه Store برابر 4 است نه 1 و نام قبلی یک ادعای عددی نادرست داشت. Unclassified هم به Mid Recency Active تغییر کرد، چون پروفایل نشان داد اعضای این خوشه در گروه Store مشتریان فعال با چرخه منظم هستند.

۶.۴ بررسی ها

بررسی	نتیجه	حکم
همپوشانی شرط ها	استنتاج اولیه ناقص بود	بازنویسی شد
حفظ تعداد ردیف ها	19,119	Pass
پوشش کامل (مشتری بی برچسب)	صفر	Pass
خوشه خالی	16 ردیف، هیچ خوشه خالی نیست	Pass
تعارض New Customer و Medium Value	944 مشتری	Pass، توضیح داده شده
سهم سطل باقی مانده	28.6 درصد Individual و 40.2 درصد Store	Fail برای Store

مهم ترین درس روشی این مرحله مربوط به بررسی همپوشانی بود. در ابتدا از اینکه جمع شمارنده های قواعد کمتر از کل مشتریان بود نتیجه گرفته شد که قواعد همپوشانی ندارند. این استنتاج غلط است. جمع کمتر از کل فقط نشان می دهد سطل باقی مانده خالی نیست. همپوشانی جمع را بالا می برد و سطل باقی مانده آن را پایین می آورد، و این دو اثر می توانند یکدیگر را بپوشانند. تعارض واقعی بعداً از اختلاف خروجی CASE با شمارنده ها کشف شد.

۷. پروفایل خوشه ها

خوشه بندی به هر مشتری برچسب می زند و پروفایل توصیف می کند هر خوشه واقعا چه شکلی دارد. برای هر خوشه در هر گروه، تعداد، سهم جمعیت، میانه سه سنج، میانگین Monetary و سهم درآمد از گروه محاسبه شد. چون توزیع Monetary به شدت چوله است، میانه مبنای توصیف است و میانگین فقط برای نشان دادن شدت چولگی آمده.

۷.۱ گروه Individual

خوشه	تعداد	سهم جمعیت	میانه R	میانه F	میانه M	میانگین M	درآمد	سهم درآمد
Mid Recency Active	5,291	28.62	201	1	103.48	1,242.83	6,575,815.20	22.40
New Customer	4,106	22.21	73	1	69.99	543.16	2,230,203.81	7.60
High Value	2,046	11.07	79	2	4,464.48	4,449.38	9,103,424.14	31.01
Churn Risk	1,814	9.81	273	2	4,397.75	4,391.16	7,965,559.87	27.13
Low Value	1,760	9.52	288	1	26.97	23.74	41,783.46	0.14
Medium Value	1,464	7.92	129	2	169.80	305.16	446,757.04	1.52
High Value Lapsed	1,258	6.81	348	1	2,398.05	2,342.37	2,946,701.76	10.04
Loyal Small Spender	745	4.03	106	2	68.70	65.01	48,431.94	0.16

۷.۲ گروه Store with rep

خوشه	تعداد	سهم جمعیت	میانه R	میانه F	میانه M	میانگین M	درآمد	سهم درآمد
Mid Recency Active	255	40.16	92	5	30,845.61	113,022.53	28,820,743.95	35.81
New Customer	88	13.86	61	4	23,432.83	72,822.41	6,408,372.01	7.96
Low Value	64	10.08	427	2	1,183.35	1,362.25	87,183.90	0.11
Medium Value	61	9.61	92	8	45,502.97	49,463.63	3,017,281.14	3.75
Churn Risk	48	7.56	122	8	345,504.49	369,603.94	17,740,989.05	22.04
High Value	43	6.77	61	9	361,999.06	357,574.48	15,375,702.83	19.10
High Value Lapsed	43	6.77	458	4	158,899.15	202,056.78	8,688,441.63	10.79
Loyal Small Spender	33	5.20	92	8	10,598.54	10,575.44	348,989.66	0.43

سهام ها به درصد و از کل گروه خود هستند. R و F به ترتیب بر حسب روز و تعداد سفارش و M بر حسب دلار است.

۷.۳ یافته ها

خوشه Churn Risk بزرگ ترین فرصت بازگردانی است. نسبت سهم درآمد به سهم جمعیت این خوشه در هر دو گروه حدود 2.8 برابر است و در مجموع 25.7 میلیون دلار، یعنی 23.4 درصد کل درآمد پروژه، را در بر می گیرد.

خوشه High Value Lapsed احتمالا از دست رفته است. میانه Recency آن 348 روز در گروه Individual و 458 روز در گروه Store است و در مجموع 11.6 میلیون دلار درآمد تاریخی دارد. خوشه Mid Recency Active گروه Store بزرگ ترین خوشه درآمدی کل پروژه است با 28.8 میلیون دلار، در حالی که به عنوان سطل باقی مانده ساخته شده بود.

خوشه New Customer گروه Individual حجم بالا و ارزش پایین دارد: 22.21 درصد جمعیت و 7.60 درصد درآمد. میانه مبلغ خرید 69.99 دلار در برابر میانگین 543.16 است.

یک ضعف در طراحی قواعد: امتیاز 3 در Recency تقریبا بدون پوشش مانده است. New و High Value Customer شرط Recency بالا دارند و Churn Risk و High Value Lapsed و Low Value شرط Recency پایین. تنها مسیر ورود امتیاز 3 به یک خوشه مشخص، Medium Value است که قید MScore برابر 3 را هم دارد. پس بیشتر مشتریان با تازگی میانی در سطل باقی مانده افتاده اند. قواعد به سراغ دو سر طیف رفتند و وسط طیف بیرون ماند.

۸. تحلیل کسب و کار

این بخش یافته های پروفایل را به توصیه قابل اقدام تبدیل می کند و چند سوالی را که از مراحل قبل باز مانده بود جواب می دهد.

۸.۱ آیا مشتریان جدید واقعا جدیدند؟

هدف: بررسی اینکه آیا اعضای خوشه New Customer واقعا مشتری تازه وارد هستند.

چرا: قاعده این خوشه بر RScore بنا شده که تازگی آخرین سفارش را می سنجد، در حالی که برچسب ادعای تازگی ورود می کند. این دو یکی نیستند. ممکن است مشتری به تازگی خرید کرده باشد ولی قبلا هم خرید کرده و مشتری تازه ای نباشد.

روش: برای هر عضو، فاصله اولین سفارش تا تاریخ مرجع محاسبه شد. مشتری وقتی جدید در نظر گرفته شد که این فاصله از یک چرخه سفارش گروهش کمتر باشد: 336 روز برای Individual و 91 روز برای Store.

نوع مشتری	تعداد اعضا	تعداد اعضای واقعا جدید	سهم (درصد)
Individual	4,106	4,106	100.00
Store with rep	88	3	3.41

تعداد اعضای هر دو گروه با جدول پروفایل مطابقت کامل دارد، که تایید می کند کپی منطق امتیازدهی در فایل های مختلف واگرایی نداشته است.

حکم: Pass برای Individual و Fail برای Store.

تصمیم: برچسب تغییر نکرد و یافته به عنوان محدودیت ثبت شد. دلیل تفاوت دو گروه این است که پایین ترین کوینتایل Frequency در گروه Store شامل مشتریان یک تا چهار سفارشی است، پس FScore برابر 1 در این گروه به معنای تک سفارشی نیست. به همین دلیل توصیه بازاریابی این خوشه به تفکیک گروه نوشته شده است.

۸.۲ آزمون چرخه سفارش فروشگاه ها

هدف: مشخص کردن اینکه آیا فاصله سفارش های متوالی هر فروشگاه حول یک چرخه ثابت است، یا میانه 91 روز حاصل میانگین گیری روی رفتارهای نامنظم است.

روش: با تابع LAG تاریخ سفارش قبلی هر فروشگاه کنار سفارش فعلی قرار گرفت و فاصله روزها محاسبه شد. این بررسی مستقیماً از جدول سفارش ها خوانده شد و به View پروژه وابسته نیست. معیار تایید از قبل تعیین شد: بیش از نیمی از فاصله ها باید در بازه 61 تا 121 روز باشند.

تعداد	فاصله (روز)
1,695	92
646	91
428	90
201	89
37	182
31	181
28	184
20	183
18	0
14	273
11	365
8	275
8	1
7	274
5	276
4	457
هر کدام 1	731, 641, 640, 639, 549, 548, 547, 456, 455, 366

از 3,171 فاصله، 2,970 فاصله یعنی 93.7 درصد در بازه 61 تا 121 روز قرار دارند. تعداد کل فاصله ها دقیقاً برابر تعداد سفارش های فروشگاه ها منهای تعداد فروشگاه هاست (3,806 منهای 635)، که تایید می کند هیچ ردیفی تکثیر یا گم نشده.

حکم: Pass.

یافته این بررسی از فرضیه اولیه قوی تر بود. کل توزیع روی مضارب یک چرخه نشسته است:

تفسیر	مقادیر (روز)	ناحیه
چرخه عادی	89 تا 92	یک چرخه
یک چرخه از دست رفته	181 تا 184	دو چرخه
دو چرخه از دست رفته	273 تا 276	سه چرخه
وقفه طولانی	365, 455 تا 547, 457 تا 639, 549 تا 731, 641	چهار چرخه و بیشتر

هیچ مقداری بین این نواحی وجود ندارد. هیچ فاصله 120 یا 150 یا 220 روزه ای در داده نیست. یعنی فروشگاه ها سفارش را به تاخیر نمی اندازند، بلکه یک چرخه کامل را رد می کنند. 18 فاصله صفر و 8 فاصله یک روزه هم در داده هست که مربوط به فروشگاه هایی است که در یک روز یا دو روز پشت سر هم بیش از یک سفارش ثبت کرده اند. این ها در توزیع باقی ماندند.

۸.۳ فرصت بازگردانی فروشگاه های غایب

هدف: تبدیل شمارش فروشگاه های غایب به یک فرصت قابل اقدام با پشتوانه مالی و اولویت بندی شده.

تعریف غیبت: در تحلیل توزیع، فروشگاه غایب با آستانه یک سال تعریف شده بود و 153 فروشگاه به دست آمده بود. حالا که مشخص شد فروشگاه ها چرخه ها را رد می کنند، فروشگاه غایب به فروشنده‌ای گفته شد که بیش از سه چرخه، یعنی بیش از 273 روز، سفارش نداده باشد. هر دو عدد با تعریف زمان خودشان درست اند.

مقدار	سنجه
163 از 635 (25.7 درصد)	تعداد فروشگاه غایب
12,991,399.27 دلار (16.1 درصد درآمد گروه Store)	درآمد تاریخی
488 روز	میانه غیبت
274 و 1,035 روز	کمترین و بیشترین غیبت

خوشه	تعداد فروشگاه غایب	درآمد تاریخی	سهم از درآمد غایب ها (درصد)	میانه غیبت (روز)
High Value Lapsed	30	6,016,081.58	46.31	792
Churn Risk	15	4,281,594.29	32.96	458
Mid Recency Active	70	2,628,883.75	20.24	547
Low Value	47	49,834.62	0.38	519
Loyal Small Spender	1	15,005.03	0.12	366

سه خوشه High Value و New Customer و Medium Value هیچ عضو غایبی ندارند، که با قید Recency بالای قواعدشان سازگار است. جمع تعداد و درآمد این جدول با کوئری کل یکی است.

یک چهارم فروشگاه ها غایب اند ولی فقط یک ششم درآمد گروه را نمایندگی می کنند. پس غیبت با ارزش همبسته نیست و تلاش یکسان روی همه فروشگاه های غایب منطقی نیست.

45 فروشگاه از خوشه های High Value Lapsed و Churn Risk، یعنی 27.6 درصد فروشگاه های غایب، 79.3 درصد درآمد تاریخی این مجموعه را دارند. در مقابل 118 فروشگاه باقی مانده فقط 20.7 درصد درآمد را نمایندگی می کنند.

در میان این دو خوشه پرارزش، Churn Risk با میانه غیبت 458 روز تازه تر غایب شده است، در برابر 792 روز برای High Value Lapsed.

۸.۴ سهم هر خوشه از کل درآمد پروژه

جدول های پروفایل سهم هر خوشه را از گروه خودش نشان می دادند و بین دو گروه قابل مقایسه نبودند. برای اولویت بندی در سطح کل شرکت، سهم هر خوشه از کل 109.8 میلیون دلار محاسبه شد.

نوع مشتری	خوشه	درآمد	سهم از کل (درصد)
Store with rep	Mid Recency Active	28,820,743.95	26.24
Store with rep	Churn Risk	17,740,989.05	16.15
Store with rep	High Value	15,375,702.83	14.00
Individual	High Value	9,103,424.14	8.29
Store with rep	High Value Lapsed	8,688,441.63	7.91
Individual	Churn Risk	7,965,559.87	7.25
Individual	Mid Recency Active	6,575,815.20	5.99
Store with rep	New Customer	6,408,372.01	5.83
Store with rep	Medium Value	3,017,281.14	2.75
Individual	High Value Lapsed	2,946,701.76	2.68
Individual	New Customer	2,230,203.81	2.03
Individual	Medium Value	446,757.04	0.41
Store with rep	Loyal Small Spender	348,989.66	0.32
Store with rep	Low Value	87,183.90	0.08
Individual	Loyal Small Spender	48,431.94	0.04
Individual	Low Value	41,783.46	0.04

جمع درآمد این جدول برابر 109,846,381.39 دلار است و با مرجع پروژه مطابقت دارد.

پنج ردیف اول 72.6 درصد کل درآمد را دارند و چهار تای آن ها متعلق به گروه Store است. اولین خوشه Individual در رتبه چهارم می آید.

خوشه Churn Risk در مجموع دو گروه 23.4 درصد کل درآمد پروژه است.

خوشه Mid Recency Active گروه Store با 26.24 درصد بزرگ ترین خوشه کل پروژه است. خوشه ای که به عنوان سطل باقی مانده ساخته شد، یک چهارم درآمد شرکت را در خود دارد.

۸.۵ جدول اولویت بندی

اولویت	خوشه و گروه	سهم از کل درآمد (درصد)	ماهیت ریسک
1	Churn Risk (هر دو گروه)	23.40	ارزش بالا و تازگی پایین، ولی هنوز قابل بازگشت
2	Mid Recency Active (Store)	26.24	بزرگ ترین خوشه درآمدی، ولی سطل باقی مانده با ترکیب داخلی ناهمگن
3	High Value (هر دو گروه)	22.29	سالم، ولی در معرض ریسک از دست رفتن
4	High Value Lapsed (هر دو گروه)	10.59	میانه غیبت بیش از یک سال و احتمال بازگشت پایین
5	باقی خوشه ها	17.48	ارزش پایین یا حجم کم

۹. محدودیت های تحلیل

محدودیت های عمومی مدل RFM در بخش آمد. این بخش محدودیت های مخصوص این تحلیل را جمع می کند.

۱. ضعف بعد Frequency که 92.4 درصد مشتریان فردی یک یا دو سفارش دارند و امتیازهای 2 و 3 در این گروه به هیچ مشتری نرسید. مدل در این گروه عملاً دوبعدی است و وزن اصلی تفکیک بر دوش Recency و Monetary است.

۲. برچسب New Customer در گروه Store. این برچسب برای 96.6 درصد اعضای خوشه در گروه Store ادعای نادرست می کند. برچسب به دلیل ساختار مشترک برچسب ها تغییر نکرد و توصیه ها به تفکیک گروه نوشته شد.

۳. ترکیب داخلی Mid Recency Active سنجیده نشده. این خوشه بزرگ ترین سهم درآمد پروژه را دارد ولی به عنوان سطل باقی مانده ساخته شده و احتمالاً ناهمگن است.

۴. فرض کاهش شانس بازگشت با مدت غیبت آزمون نشده. این فرض مبنای اولویت دادن به Churn Risk بر High Value Lapsed است. داده پروژه هیچ مورد بازگشت بعد از غیبت طولانی ندارد که بتوان از آن نرخ استخراج کرد. این یک فرض رایج در صنعت است، نه یافته این تحلیل.

۵. مشتریان بدون سفارش بررسی نشدند. 701 مشتری بدون سفارش که همگی فروشگاه های بدون نماینده فروش هستند، فقط به عنوان یک مشاهده گزارش می شوند. درباره اینکه آیا فرصت واقعی فعال سازی هستند یا رکورد اداری، ادعایی نمی توان کرد.

۶. شناسایی اشخاص تکراری انجام نشد. اگر یک شخص با بیش از یک شناسه مشتری ثبت شده باشد، تعداد سفارش و مبلغ خریدش بین دو رکورد تقسیم می شود.

۷. آستانه چرخه از مشتریان چندسفارشی آمده. میانه فاصله سفارش فقط از مشتریان چندسفارشی محاسبه شده و استفاده از آن برای همه مشتریان، از جمله تک سفارشی ها، یک فرض است.

۸. Monetary درآمد ناخالص است. حاشیه سود در دسترس نبود و مالیات و هزینه حمل عمدا کنار گذاشته شدند.

۹. تکرار منطق امتیازدهی در چند فایل. امتیازها به عنوان شی پایگاه داده ذخیره نشدند و زنجیره CTE در چند فایل تکرار شده. تطابق کامل تعداد اعضای خوشه ها در بخش ۸.۱ نشان داد تا این لحظه واگرایی رخ نداده، ولی ریسک آن در تغییرات آینده باقی است.

۱۰. نتیجه گیری

این پروژه نشان داد اجرای مکانیکی RFM روی داده AdventureWorks نتیجه گمراه کننده ای می داد. دو گروه مشتری با چرخه خرید 91 و 336 روزه در یک جمعیت ترکیب شده اند و روش متعارف امتیازدهی با NTILE توده های بزرگ هم مقدار را بی صدا می شکند. امتیازدهی جداگانه برای هر نوع مشتری و استفاده از PERCENT_RANK این دو مشکل را حل کرد، به قیمت چند سطح امتیاز خالی که دلیلشان مستند شده است.

از نظر کسب و کار، درآمد شرکت به شدت به فروشگاه ها وابسته است و بزرگ ترین ریسک در خوشه در خطر ریزش با 23.4 درصد کل درآمد متمرکز است. الگوی چرخه ای خرید فروشگاه ها یک تعریف رفتاری برای غیبت فراهم کرد و نشان داد 45 فروشگاه ارزشمند غایب حدود 79 درصد درآمد تاریخی فروشگاه های غایب را در اختیار دارند. تمرکز تلاش بازگردانی روی همین گروه کوچک، بیشترین بازده را خواهد داشت.

مهم ترین مسیر برای ادامه این کار، بررسی ترکیب داخلی خوشه Mid Recency Active در گروه Store است، چون این خوشه بزرگ ترین سهم درآمد پروژه را دارد و در طراحی فعلی به عنوان سطل باقی مانده ساخته شده است.